Résolution de toponymes par apprentissage profond à partir de cooccurrences et de relations spatiales

Jacques Fize [1] Ludovic Moncla [1] Bruno Martins [2]

[1]LIRIS UMR 5205, INSA Lyon, France [2]Instituto Superior Técnico - INESC-ID, University of Lisbon, Portugal

Résolution de toponymes

La **résolution de toponymes** (ou *geocoding*) fait partie de la tâche de geoparsing (processus permettant l'**identification** et **la géolocalisation des lieux mentionnés dans un texte** [Gritta et al., 2018]). Elle est généralement utilisée en complément de l'étape de repérage des noms de lieux :

1. **Geotagging.** Identification des noms de lieux (reconnaissance d'entités nommées)
2. **Geocoding.** Association d'une localisation (coordonnées géographiques).

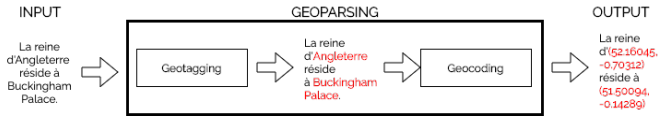

Figure 1. Processus de geoparsing

Dans ce travail, nous proposons une approche pour entraîner des modèles de geocoding [DeLozier et al., 2015, Cardoso et al., 2019] afin de ne pas avoir à utiliser de gazetteers lors de l'étape de geocoding. L'architecture que nous proposons pour l'entraînement des modèles prend en entrée des paires de toponymes. Le premier est celui que l'on cherche à localiser, le second sert de contexte.

Hypothèse

Notre proposition s'appuie sur l'utilisation de **plusieurs types de contextes** pour la construction des paires du jeu de données d'entrée (cooccurrences et relations spatiales) et sur la **régionalité de certains affixes dans les noms de lieux** (Voir Fig. 2).

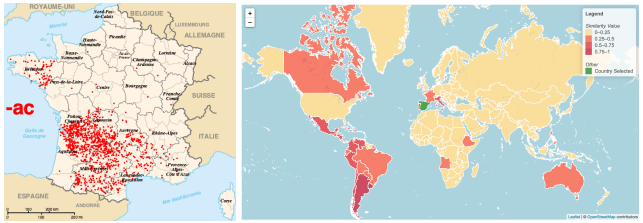

(a) dont le suffixe est *-ac* (en France) (b) d'Espagne et les autres pays

Figure 2. Similarité entre les noms de lieux

Les données

Nous utilisons deux sources de données différentes pour constituer les paires de toponymes en fonction du contexte.

- **Contexte spatial.** Les données de **Geonames** sont utilisées pour constituer les paires de toponymes en s'appuyant sur la proximité ou l'inclusion qui existe entre les deux lieux.
- **Contexte textuel.** Les paires de toponymes sont générés à l'aide des cooccurrences existantes entre les lieux au sein des pages de **Wikipedia**.

Dans le but d'améliorer les performances du modèle, différentes configurations impliquant les combinaisons de ces contextes ont été testées et sont présentées dans la section *Expérimentation et résultats*.

L'architecture

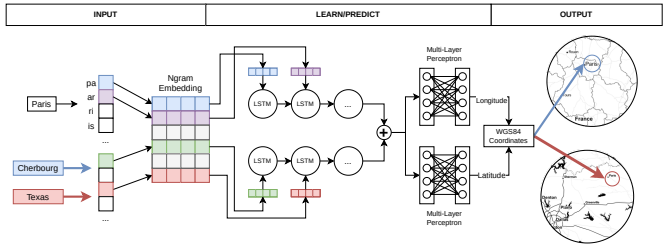

Figure 3. Architecture pour l'entraînement d'un modèle de geocoding.

Nous proposons une architecture s'appuyant sur un réseau de neurones récurrent (Bi-LSTM) avec :

- **En entrée.** Un couple de toponyme, le premier est le toponyme que l'on souhaite géolocaliser et le second est utilisé comme contexte
- **En sortie.** Les coordonnées (en latitude-longitude) prédites par le modèle du premier toponyme.

Chaque toponyme est décomposé en séquence de ngram de caractères. Une comparaison des performances de notre modèle selon la taille de n-gram indique que de meilleurs résultats sont obtenus avec $n > 3$. Par exemple, pour $n = 4$ le toponyme **La Rochelle** devient *{$$$L, $$La, La, LaR, a$Ro, $Roc, Roch, oche, chel, hell, elle, lle$, le$$, e$$$}*

Protocole d'évaluation

- Différents jeux de données d'apprentissage et de geocoding selon le pays : France, Royaume-Uni, États-Unis, Japon, Argentine, Nigeria
- Score : Accuracy@k, ou $A@k(F,T)$ ou F correspond au coordonnées prédites et T les coordonnées attendues.

$$A@k(F,T) = \frac{1}{|F|} \times \sum_{i=0}^{|F|} \begin{cases} 1, & \text{if } distance(F_i, T_i) < k \\ 0, & \text{sinon} \end{cases}$$

- Jeux de données d'évaluation : *Geocoding* de pages de lieux sur Wikipedia.

Expérimentations et résultats

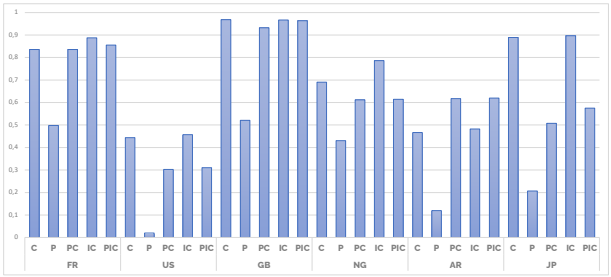

Figure 4. Exactitude de notre modèle selon la combinaison des contextes utilisée (C = Cooccurrences ; C = Proximité ; I = Inclusion)

Apport du contexte spatial pour certains pays

Pour les pays avec peu d'articles dans Wikipedia, l'ajout de paires de toponymes basées sur les relations spatiales améliore les résultats.

	# paires		Accuracy @100km	
	C	P	C	PC
FR	714 974	985 090	0,8359	0,8359
AR	9 378	3 052 000	0,4669	0,6176

Table 1. Impact de la combinaison de contextes sur les performances (P= Proximité, C= Cooccurrence)

Impact du *sampling*

Le nombre total de paires de toponymes pour un pays pouvant être très élevé, nous effectuons une sélection d'un échantillon. La Fig. 5 montre l'impact positif d'un échantillonnage plus grand sur l'entraînement du modèle.

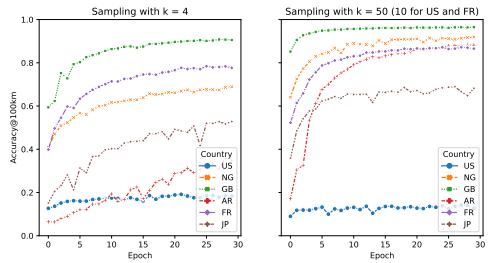

Figure 5. Évaluation lors de l'entraînement des modèles.

Remerciements

Ces travaux s'inscrivent dans le projet HextGEO réalisé grâce au soutien financier du projet IDEXLYON de l'Université de Lyon, dans le cadre du programme Investissement d'Avenir (ANR-16-IDEX-0005). Ces travaux ont bénéficié d'un accès aux moyens de calcul de l'IDRIS au travers de l'allocation de ressources 2020-AD011011551R1 attribuée par GENCI.

References

[Cardoso et al., 2019] Cardoso, A. B., Martins, B., and Estima, J. (2019).
Using Recurrent Neural Networks for Toponym Resolution in Text.
In *Proceedings of the EPIA Conference on Artificial Intelligence*, pages 769–780. Springer International Publishing.

[DeLozier et al., 2015] DeLozier, G., Baldridge, J., and London, L. (2015).
Gazetteer-Independent Toponym Resolution Using Geographic Word Profiles.
In *Proceedings of the 29th AAAI Conference on Artificial Intelligence*.

[Gritta et al., 2018] Gritta, M., Pilehvar, M. T., Limsopatham, N., and Collier, N. (2018).
What's missing in geographical parsing ?
Language Resources and Evaluation, 52(2):603–623.

LaRochelle 5-7 mai 2021

SAGEO 2021, 16th Spatial Analysis and Geomatics Conference