Services Web pour l'annotation sémantique d'information spatiale à partir de corpus textuels

***Ludovic Moncla*[1], *Mauro Gaio*[2]**
[1] *IRENav, CC 600, 29240 Brest Cedex 9, France*
[2] *LIUPPA, Université de Pau et des Pays de l'Adour, 64000 Pau, France*

ludovic.moncla@ecole-navale.fr, mauro.gaio@univ-pau.fr

Introduction

Contexte

Annoter du texte avec des marques géo-sémantiques ?

à titre d'exemple

"L'exploration de corpus" dans le cadre des Humanités Numériques.

- Un corpus de romans du XIXe
  L'Assommoir du père Colombe se trouvait au coin de la rue des Poissonniers et du boulevard de Rochechouart.
- Des inventaires forestiers fin XIXe
  À l'origine, le canton de Liberty était fortement couvert de bois d'œuvre fin, englobant des variétés telles que le chêne blanc et rouge, l'érable à sucre(...)
- Des récits de voyage dans les Pyrénées du XIXe
  Arrivé au plus haut de ce vallon, on découvre la vallée de Cauterez sous ses pieds et sur sa tête Vignemale en cône tronqué(...)

Introduction

Annoter du texte + ou - automatiquement

Marquage simple des “noms propres”

forme la plus basique de l’entité nommée (EN)

“L’exploration de corpus” dans le cadre des Humanités Numériques.

- Un corpus de romans du XIXe
  L’Assommoir du père Colombe se trouvait au coin de la rue des Poissonniers et du boulevard de Rochechouart.
- Des inventaires forestiers fin XIXe
  À l’origine, le canton de Liberty était fortement couvert de bois d’œuvre fin, englobant des variétés telles que le chêne blanc et rouge, l’érable à sucre(. . .)
- Des récits de voyage dans les Pyrénées du XIXe
  Arrivé au plus haut de ce vallon, on découvre la vallée de Cauterez sous ses pieds et sur sa tête Vignemale en cône tronqué(. . .)

Problématique

Selon objectifs

Marquages associant “noms propres” et “noms descriptifs”

EN de niveau plus élaboré

“L’exploration de corpus” dans le cadre des Humanités Numériques.

- Un corpus de romans du XIXe
  L’Assommoir du père Colombe se trouvait au coin de la rue des Poissonniers et du boulevard de Rochechouart.
- Des inventaires forestiers fin XIXe
  À l’origine, le canton de Liberty était fortement couvert de bois d’œuvre fin, englobant des variétés telles que le chêne blanc et rouge, l’érable à sucre(. . .)
- Des récits de voyage dans les Pyrénées du XIXe
  Arrivé au plus haut de ce vallon, on découvre la vallée de Cauterez sous ses pieds et sur sa tête Vignemale en cône tronqué(. . .)

Problématique

Selon objectifs

Marquages associant EN et “leurs relations”

EN + relations spatiales

“L’exploration de corpus” dans le cadre des Humanités Numériques.

- Un corpus de romans du XIXe
  L’Assommoir du père Colombe se trouvait au coin de la rue des Poissonniers + et du boulevard de Rochechouart.
- Des inventaires forestiers fin XIXe
  À l’origine, le canton de Liberty était fortement couvert de bois d’œuvre fin, englobant des variétés telles que le chêne blanc et rouge, l’érable à sucre(. . .)
- Des récits de voyage dans les Pyrénées du XIXe
  Arrivé au plus haut de ce vallon, on découvre la vallée de Cauterez sous ses + pieds et sur sa tête Vignemale en cône tronqué(. . .)

Problématique

Selon objectifs

Marquages associant EN “statiques et relations dymaniques”

“L’exploration de corpus” dans le cadre des Humanités Numériques.

- Un corpus de romans du XIXe
  L’Assommoir du père Colombe se trouvait au coin de la rue des Poissonniers + et du boulevard de Rochechouart.
- Des inventaires forestiers fin XIXe
  À l’origine, le canton de Liberty était fortement couvert de bois d’œuvre fin, englobant des variétés telles que le chêne blanc et rouge, l’érable à sucre(. . .)
- Des récits de voyage dans les Pyrénées du XIXe
  Arrivé au plus haut de ce vallon, on découvre la vallée de Cauterez sous ses + pieds et sur sa tête Vignemale en cône tronqué(. . .)

Conséquences

ou leçon à tirer

L'ensemble de l'expression évoquant une entité doit être considérée.

1. Permettre de réduire les erreurs de bornes ou de classes,
2. Obtenir des annotations et des catégorisations de qualité.

Marcher 10 km jusqu'au refuge des Barmettes

Conséquences

ou leçon à tirer

L'ensemble de l'expression évoquant une entité doit être considérée.

1. Permettre de réduire les erreurs de bornes ou de classes,
2. Obtenir des annotations et des catégorisations de qualité.

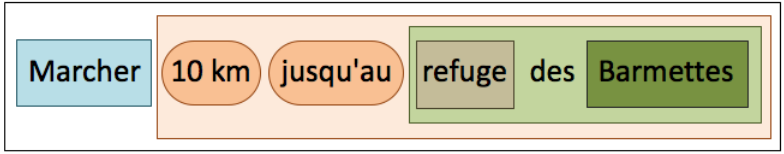

Outillage

Annoter avec quoi ?

- Manuellement ;
- Semi-automatiquement avec des outils de textométrie/lexicométrie *(TXM, Knime, Glozz)* ;
- Automatiquement avec des chaines ad-hoc *(NLTK, UIMA, GATE, TextMining with R, Unitex)*

Et avec quel langage de marquage ?

- TEI : <Text Encoding Initiative>
  `http://www.tei-c.org/`
- ISO-Space + ISO-TimeML
  `https://www.iso.org/obp/ui#iso:std:iso:24617:-7:2014`
- XML ou autre langage ad-hoc

Outillage

Quelle plateforme ?

Pourquoi pas la composer soi même en combinant des services Web :

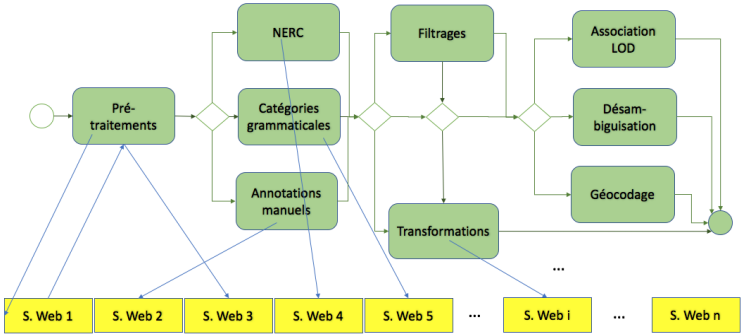

Comme préconisé par la plupart des plateformes, telles que :

- *Watson (ancien Alchemy)*
  `https://www.ibm.com/watson/services/natural-language-understanding/`
- *Dandelion* `https://dandelion.eu/`
- *TextRazor* `https://www.textrazor.com/demo`
- *API Cloud Natural Language* `https://cloud.google.com/natural-language/`

Info. géo. statique ou dynamique

Espace et dynamicité dans les langues romanes

(1) a. *il portavoce di* *Villa Medici* a *Roma*

b. *il giardino di* *Villa Medici a* *Roma*

'porte parole/jardin de la Villa Médicis à Rome'

L'aspect statique : les Entités Nommées (EN)

- **Catégorisation :** personne, lieu, organisation, valeur, temps, produit, fonction . . .
  (Sekine, 2004 ; Tran, 2006 ; Ehrmann 2008)

  Sekine propose le concept de : Extended Named Entity (ENE)
- **NERC :** Marquage et extraction par catégories pré-définies
  (Nadeau and Sekine, 2007 ; Friburger and Maurel, 2004 ; C. Marquesuzaà et al, 2016)
- **EN de lieu et ENES :** spécificités
  (Leidner, 2004 : Gaio et al., 2008)

Info. géo. statique ou dynamique

Espace et dynamicité dans les langues romanes

(2) a. Il [*parvient* (*au/au pied de*)] [*Col de la Vanoise*]

b. On [*est parti* (*du/au*)] [*refuge des* [*Barmettes*]]

L'aspect dynamique : verbe ou syntagme verbal

- Catégorisation des **verbes :** état, movement, déplacement, perception . . .
  polarité des verbes de déplacement : initial (*partir*), median (*traverser*), final (*arriver*)
- Catégorisation des **prépositions :** temporelle, locative, . . .
  polarité du syntagme verbal : (*partir de*, *partir à*)
- Catégorisation des **adverbes :** lieu, temps, manière, négation . . .

(Boons, 1987 ; Laur, 1993 ; Muller, 1998 ; Aurnague, 2011)

Info. géo. statique ou dynamique

Espace et dynamicité dans les langues romanes

Il faut 2h pour atteindre le cirque de Gavarnie en prenant le sentier à l'ouest du village qui court le long du ruisseau.

L'aspect dynamique : les relations spatiales et spatio-temporelles

- entre objet de référence (*ground*, *site*) et objet à localiser (*figure*, *target*)
- entre le(s) objet(s), l'action et l'acteur

(Talmy, 1985 ; Vandeloise, 1986 ; Aurnague and Vieu, 2015)

Annotation des aspects statique et dynamique

Vue d'ensemble

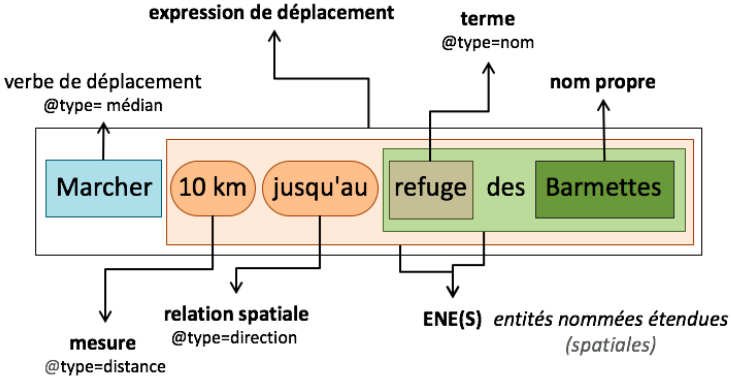

Annotation de l'aspect statique

Entité Nommée Étendue (ENE)

Deux catégories de noms propres (K. Jonasson, 1994)

- **pur :** Nom propre seul (simple ou composée)
- **descriptif :** composition de nom(s) propre(s) et d'une extension
  - l'extension (nom commun) peut changer le type "par défaut" de l'EN (lieu, personne, institution)

L'entité Nommée Étendue (Spatiale) (L. Moncla et Gaio.M., 2015)

- composée à partir d'un nom propre pur ou descriptif
- peut être constituée de différents niveaux de recouvrement

Annotation de l'aspect statique

Entité Nommée Étendue (ENE)

Niveau 0

(3) a. *Gave de Pau* → entité de type : `lieu`

b. *Greenpeace* → entité de type : `organisation`

c. *Guillaume le Conquérant* → entité de type : `personne`

Niveau 1 : type inchangé

- l'extension descriptive ne change pas la nature "par défaut ou implicite" de l'entité nommée avec le nom propre

(4) a. *comunidad autónoma de* *Aragón*

b. *gave de* *Pau*

Annotation de l'aspect statique

Entité Nommée Étendue (ENE)

Niveau 1 : changement de type

- ici la nature "par défaut ou implicite" de l'entité nommée est modifiée

(5) *maire de* $\boxed{\textit{Rouen}}$
→ deux entités, ***Rouen*** (`lieu`) et ***maire de Rouen*** (`personne`)

Niveau > 1

(6) *il giardino di* $\boxed{\textit{Villa Medici a } \boxed{\textit{Roma}}}$
'le jardin Villa Médicis à Rome'
→ trois entités, ***Rome*** (`lieu`), ***Villa Medici a Roma*** (`lieu`) et ***il giardino di Villa Medici a Roma*** (`lieu`)

Annotation de l'aspect dynamique

Les expressions de déplacement

Constructions sémantico-syntaxique

- éléments syntaxiques : syntagme verbal , syntagme prépositionnel et/ou syntagme adverbial, syntagme nominal, conjonction
- éléments sémantiques : action de déplacement, relation spatiale, ENE (liste)

(7) *Emprunter successivement* ***rue des Capucins*** *et* ***rue de Compostelle****.*

(8) *Prendre à gauche après l'entrée de* ***l'usine de Fontanille****.*

(9) *Suivre la route depuis le* ***hameau Lic*** *jusqu'à la* ***Chapelle Saint-Roche****.*

Les services PERDIDO

Implémentation

Quelques détails sur les premiers services disponibles :

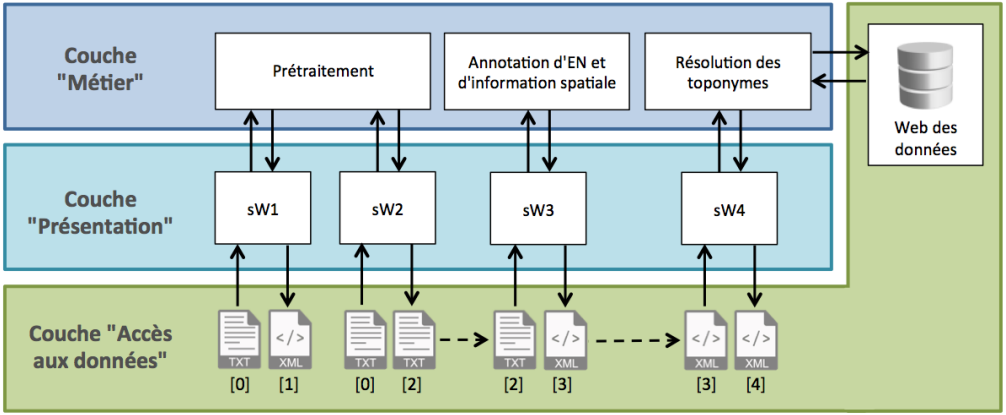

Les services PERDIDO

Implémentation : Services dédiés aux pré-traitements

Services disponibles : parseurs morpho-syntaxiques (POS) pour les langues romanes (treetagger, talismane, freeling)

`http://erig.univ-pau.fr/PERDIDO/api.jsp#pos`

- Exemple

  http ://erig.univ-pau.fr/PERDIDO/api/preprocessing/pos/tei/ ?(params)

Entrée : texte brut,
"Poursuivez par le Col de la Vanoise"

Sortie : texte annoté avec les cat. grammaticales dans le DSL (conforme **TEI**)

```
...
<s><w lemma="poursuivre" pos="VER:pres">Poursuivez</w>
<w lemma="par" pos="PREP">par</w>
<w lemma="le" pos="DET">le</w>
<w lemma="Col␣de␣la␣Vanoise" pos="Npr">Col de la Vanoise</w></s>
...
```

Les services PERDIDO

Implémentation : Services d'annotation des ENE(S)

Services disponibles : Annotations selon le DSL défini dans :

A multi-layer markup language for geospatial semantic annotations.
(Moncla, L. et Gaio, M. (GIR'15), Paris, France 2015)

`http://erig.univ-pau.fr/PERDIDO/api.jsp#esne`

- Exemple : *ENE non catégorisée*

  http ://erig.univ-pau.fr/PERDIDO/api/parsingTEI/generic/ ?(params)

  Entrée : texte brut ou POS annoté (format Unitex)
  "Marchez 10 Km jusqu'au refuge des Barmettes"

  Sortie : texte annoté avec les **ENE non catégorisées + info spatiales associées**

```
<phr type="verb_phrase" subtype="motion"> Marcher
 <measure type="distance">10 km<\offset>
  <offset type="direction" subtype="final">jusqu'au<\offset>
  <rs n="1">
    <term type="N">refuge</term> des
    <rs n="0">
      <name>Barmettes</name>
    </rs>
  </rs>
  </phr>
```

Les services PERDIDO

Implémentation : Services d'annotation des ENE(S)

Services disponibles : Annotations selon le DSL (Moncla, L. et Gaio, M., GIR'15)

- Exemple : *ENE Spatiale*

  http ://erig.univ-pau.fr/PERDIDO/api/parsingTEI/spatial/ ?(params)

  Entrée : texte brut ou POS annoté

  "Marchez 10 km jusqu'au refuge des Barmettes"

  Sortie : texte annoté (TEI) avec les **ENE non cat. et les ENES + info spatiales associées**

```
<s>  <phr type="verb_phrase" subtype="motion">Marchez
      <measure type="distance">10 km</measure>
      <offset type="direction"
          subtype="initial">jusqu'au</offset>
      <placeName n="1"
          ref="www.openstreetmap.org/node/451703419">
              <geogName type="S" subtype="RHSE">
                <geogFeat>refuge</geogFeat>des
                    <name>Barmettes</name>
              </geogName>
            </placeName>
       </phr>  </s>
```

Conclusion

Evaluation

Corpus > 100 documents

- Descriptions de randonnées
- Français, Espagnol, Italien

	ENE	*Perdido*	
level 0	304	244	80%
level 1	332	280	84%
level 2	20	17	85%
level 3	4	1	25%
total	**660**	**542**	**82%**

TABLE – Nombre d'entités correctement annotées (Corpus Français)

Conclusion

Application construite à partir des SW

Démonstrateur : `http://erig.univ-pau.fr/PERDIDO/`

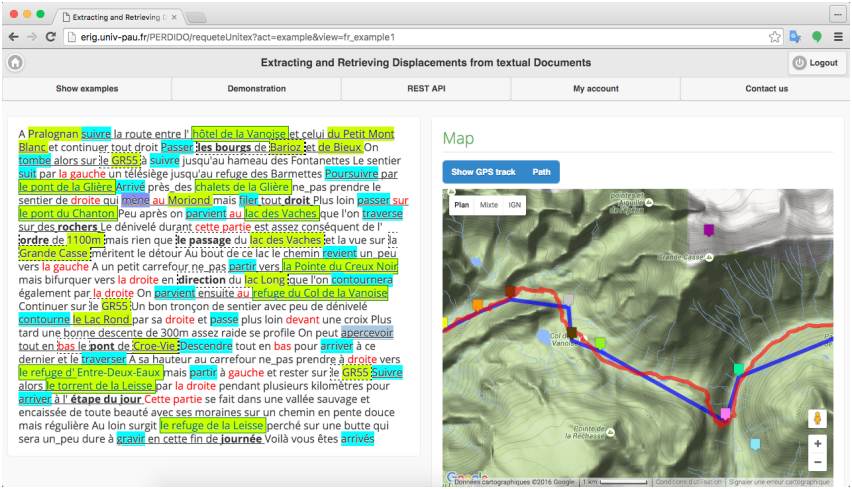

Futures aventures dans le projet ANR-CHOUCAS `choucas.ign.fr`

Merci pour votre attention

CONTACT

Mauro Gaio (LIUPPA)
mauro.gaio@univ-pau.fr

Ludovic Moncla (IRENav)
ludovic.moncla@ecole-navale.fr

Ce travail a bénéficié du soutien :

UNIVERSITÉ DE PAU ET DES PAYS DE L'ADOUR

1542 IAAA Sistemas de Información Avanzados Universidad Zaragoza

IGN INSTITUT NATIONAL DE L'INFORMATION GÉOGRAPHIQUE ET FORESTIÈRE

Pau Porte des Pyrénées Communauté d'agglomération