An automatic extraction method of static and dynamic spatial context from texts

L. Moncla, M. Gaio, E. Egorova et C. Claramunt

ECOLE NAVALE

UNIVERSITÉ DE PAU ET DES PAYS DE L'ADOUR

University of Zurich[UZH]
Department of Geography

L. Moncla
ludovic.moncla@ecole-navale.fr

Atelier SDHN EGC 2018

SOMMAIRE

1. Introduction
2. Annotation de l'aspect statique
3. Annotation de l'aspect dynamique
4. Mouvement fictif
5. Conclusion

Introduction

Contexte

"L'exploration de corpus" dans le cadre des Humanités Numériques.

Annoter du texte avec des marques géo-sémantiques ?

- Un corpus de romans du XIXe
  L'Assommoir du père Colombe se trouvait au coin de la rue des Poissonniers et du boulevard de Rochechouart.
- Des inventaires forestiers fin XIXe
  À l'origine, le canton de Liberty était fortement couvert de bois d'œuvre fin, englobant des variétés telles que le chêne blanc et rouge, l'érable à sucre(. . .)
- Des récits de voyage dans les Pyrénées du XIXe
  Arrivé au plus haut de ce vallon, on découvre la vallée de Cauterez sous ses pieds et sur sa tête Vignemale en cône tronqué(. . .)

Introduction

Contexte

“L’exploration de corpus” dans le cadre des Humanités Numériques.’

Marquage simple des “noms propres”
forme la plus basique de l’entité nommée (EN)

- Un corpus de romans du XIXe
  L’Assommoir du père Colombe se trouvait au coin de la rue des Poissonniers et du boulevard de Rochechouart.
- Des inventaires forestiers fin XIXe
  À l’origine, le canton de Liberty était fortement couvert de bois d’œuvre fin, englobant des variétés telles que le chêne blanc et rouge, l’érable à sucre(. . .)
- Des récits de voyage dans les Pyrénées du XIXe
  Arrivé au plus haut de ce vallon, on découvre la vallée de Cauterez sous ses pieds et sur sa tête Vignemale en cône tronqué(. . .)

Introduction

Contexte

“L’exploration de corpus” dans le cadre des Humanités Numériques.’

Marquages associant “noms propres” et “noms descriptifs” : EN de niveau plus élaboré

- Un corpus de romans du XIXe
  L’Assommoir du père Colombe se trouvait au coin de la rue des Poissonniers et du boulevard de Rochechouart.
- Des inventaires forestiers fin XIXe
  À l’origine, le canton de Liberty était fortement couvert de bois d’œuvre fin, englobant des variétés telles que le chêne blanc et rouge, l’érable à sucre(. . .)
- Des récits de voyage dans les Pyrénées du XIXe
  Arrivé au plus haut de ce vallon, on découvre la vallée de Cauterez sous ses pieds et sur sa tête Vignemale en cône tronqué(. . .)

Introduction

Contexte

“L’exploration de corpus” dans le cadre des Humanités Numériques.’

Marquages associant EN et “leurs relations” : EN + relations spatiales

- Un corpus de romans du XIXe
  L’Assommoir du père Colombe se trouvait au coin de la rue des Poissonniers + et du boulevard de Rochechouart.
- Des inventaires forestiers fin XIXe
  À l’origine, le canton de Liberty était fortement couvert de bois d’œuvre fin, englobant des variétés telles que le chêne blanc et rouge, l’érable à sucre(. . .)
- Des récits de voyage dans les Pyrénées du XIXe
  Arrivé au plus haut de ce vallon, on découvre la vallée de Cauterez sous ses + pieds et sur sa tête Vignemale en cône tronqué(. . .)

Introduction

Contexte

“L’exploration de corpus” dans le cadre des Humanités Numériques.’

Marquages associant EN “statiques et relations dynamiques’

- Un corpus de romans du XIXe
  L’Assommoir du père Colombe se trouvait au coin de la rue des Poissonniers + et du boulevard de Rochechouart.
- Des inventaires forestiers fin XIXe
  À l’origine, le canton de Liberty était fortement couvert de bois d’œuvre fin, englobant des variétés telles que le chêne blanc et rouge, l’érable à sucre(. . .)
- Des récits de voyage dans les Pyrénées du XIXe
  Arrivé au plus haut de ce vallon, on découvre la vallée de Cauterez sous ses + pieds et sur sa tête Vignemale en cône tronqué(. . .)

Introduction

Solution proposée

L'ensemble de l'expression évoquant une entité doit être considérée.

1. Permettre de réduire les erreurs de bornes ou de classes,
2. Obtenir des annotations et des catégorisations de qualité.

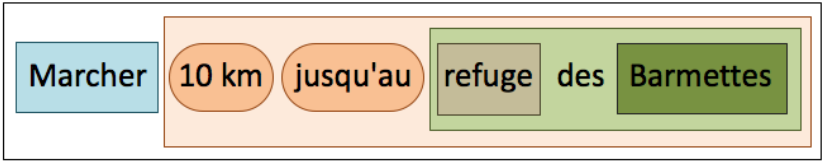

Introduction

Solution proposée

L'aspect statique : les Entités Nommées (EN)

- Catégorisation : personne, lieu, organisation (Sekine, 2004 ; Tran, 2006 ; Ehrmann, 2008)
- NERC : marquage et extraction par catégories pré-définies (Nadeau and Sekine, 2007 ; Friburger and Maurel, 2004)

L'aspect dynamique

- Verbes et syntagme verbal
- Catégorisation des verbes, des prépositions, des adverbes (Boons, 1987 ; Laur, 1993 ; Muller, 1998 ; Aurnague, 2011)

Mouvement fictif

- Détection et catégorisation des expressions de mouvements fictifs (Matsumoto, 1996 ; Egorova et al., 2016)

SOMMAIRE

1 Introduction

2 **Annotation de l'aspect statique**
- Entité Nommée Étendue (ENE)
- La plateforme PERDIDO
- Extraction des noms de lieux dans les romans

3 Annotation de l'aspect dynamique

4 Mouvement fictif

5 Conclusion

Annotation de l'aspect statique

Entité Nommée Étendue (ENE)

Deux catégories de noms propres (K. Jonasson, 1994)

- **pur :** Nom propre seul (simple ou composée)
- **descriptif :** composition de nom(s) propre(s) et d'une extension
  - l'extension (nom commun) peut changer le type "par défaut" de l'EN (lieu, personne, institution)

L'entité Nommée Étendue (Spatiale) (L. Moncla et Gaio.M., 2015)

- composée à partir d'un nom propre pur ou descriptif
- peut être constituée de différents niveaux de recouvrement

Annotation de l'aspect statique

Entité Nommée Étendue (ENE)

Niveau 0

(1) a. *Gave de Pau* → entité de type : `lieu`

b. *Greenpeace* → entité de type : `organisation`

c. *Guillaume le Conquérant* → entité de type : `personne`

Niveau 1 : type inchangé

- l'extension descriptive ne change pas la nature "par défaut ou implicite" de l'entité nommée avec le nom propre

(2) a. *comunidad autónoma de* *Aragón*

b. *ville de* *Paris*

Annotation de l'aspect statique

Entité Nommée Étendue (ENE)

Niveau 1 : changement de type

- ici la nature "par défaut ou implicite" de l'entité nommée est modifiée

(3) *maire de* $\boxed{\textit{Paris}}$
→ deux entités, ***Paris*** (`lieu`) et ***maire de Paris*** (`personne`)

Niveau > 1

(4) *il giardino di* $\boxed{\textit{Villa Medici a } \boxed{\textit{Roma}}}$
'le jardin Villa Médicis à Rome'
→ trois entités, ***Rome*** (`lieu`), ***Villa Medici a Roma*** (`lieu`) et ***il giardino di Villa Medici a Roma*** (`lieu`)

Annotation de l'aspect statique

La plateforme PERDIDO

Méthode hybride pour la reconnaissance d'entités nommées

1. Prétraitement : analyse grammaticale
   - (Treetagger, Talismane, Freeling)
2. Annotation générique des ENE
   - cascade de transducteurs (graphes Unitex et cascades CasSys)
3. Catégorisation et désambiguïsation
   - Interrogation du Web des données (IGN, Geonames, OpenStreetMap)

- chaîne de traitement implémentée pour 3 langues romanes (Français, Espagnol et Italien)
- annotations au format XML/TEI
- `http://erig.univ-pau.fr/PERDIDO/`

Annotation de l'aspect statique

Extraction des noms de lieux dans les romans

Cartographie romanesque du Paris du XIXe (L. Moncla et al., 2017)

- Corpus de 31 romans français du XIXe siècle sur Paris
  - (*Le père Goriot*, Balzac ; *Les Misérables*, Hugo ; etc)
- Extraire les noms de lieux (en particulier les rues)
- Géolocaliser ces lieux grâce à une base de données géographique historique

(5) a. *la rue* [*La Fayette*]

b. *le quartier de la* [*Goutte-d'Or*]

Annotation de l'aspect statique

Extraction des noms de lieux dans les romans

Termes géographiques les plus fréquents au sein des ENE du corpus

Terme	Occurrences	Terme	Occurrences
rue	2583	quartier	106
boulevard	257	porte	105
maison	200	place	81
faubourg	149	bois	75
hôtel	134	avenue	68
pont	123	barrière	62
quai	122	route	58

- 112 termes géographiques distincts ont été répertoriés dans le corpus

Annotation de l'aspect statique

Extraction des noms de lieux dans les romans

```
<placeName type="relative" subtype="compound">
  <offset type="inclusion">
    <w lemma="au" type="PREPDET">au</w>
    <w lemma="coin" type="PREP">coin</w>
    <w lemma="de" type="PREP">de</w>
  </offset>
  <placeName n="1" type="absolute">
    <geogName type="R" subtype="ST">
      <w lemma="le" type="DET">la</w>
      <geogFeat>
        <w lemma="rue" type="N">rue</w>
      </geogFeat>
      <w lemma="de" type="PREP">des</w>
      <name>
        <w lemma="Poissonniers" type="NPr">Poissonniers</w>
      </name>
    </geogName>
  </placeName>
  [...]
</placeName>
```

Annotation de l'aspect statique

Extraction des noms de lieux dans les romans

Carte montrant le nombre d'occurrences des noms de rue

SOMMAIRE

1 Introduction

2 Annotation de l'aspect statique

3 **Annotation de l'aspect dynamique**
- Grammaire VT
- Reconstruction automatique d'itinéraires

4 Mouvement fictif

5 Conclusion

Annotation de l'aspect dynamique

Grammaire VT

Constructions sémantico-syntaxique : grammaire VT

- éléments syntaxiques : syntagme verbal , syntagme prépositionnel et/ou syntagme adverbial, syntagme nominal, conjonction
- éléments sémantiques : action de déplacement, relation spatiale, ENE (liste)

(6) Emprunter successivement **rue des Capucins** et **rue de Compostelle**.

(7) Prendre à gauche après l'entrée de **l'usine de Fontanille**.

(8) Suivre la route depuis le **hameau Lic** jusqu'à la **Chapelle Saint-Roche**.

Annotation de l'aspect dynamique

Reconstruction d'itinéraires à partir de textes

Reconstruction automatique d'itinéraires (L. Moncla et al., 2016)

- Corpus de 90 descriptions de randonnées
- Approche multicritères utilisant informations du texte et données géographiques extraites de ressources externes

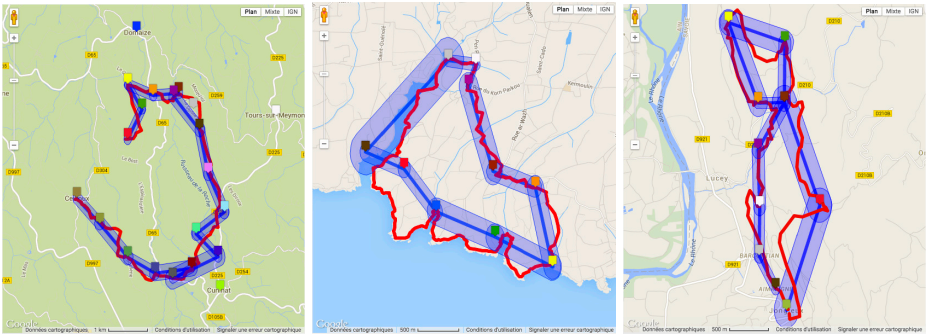

(a) (b) (c)

Annotation de l'aspect dynamique

Reconstruction d'itinéraires à partir de textes

Evaluation du corpus

- 810 occurrences d'ENE spatiales associées à une expression de déplacement (53% des ENE)
- 47% des ENE sont composés d'au moins un terme (niveau d'imbrication > 0)

Evaluation de la reconnaissance d'ENE avec PERDIDO

	# d'ENE	*Rappel*	*Précision*	*SER*
Français	660	95%	96%	17%
Espagnol	421	97%	99%	15%
Italien	475	84%	98%	32%
total	1556	92%	97%	21%

SOMMAIRE

1 Introduction

2 Annotation de l'aspect statique

3 Annotation de l'aspect dynamique

4 **Mouvement fictif**

5 Conclusion

Mouvement fictif

Identification et catégorisation automatique

Objectifs

- Identifier et catégoriser automatiquement les expressions de mouvements fictifs
- Expérimentations faites sur le corpus anglais de littérature alpine "Text+Berg"

(9) Down below us the glacier snaked away.

Proposition

- Identification des expressions basée sur la présence d'un terme géographique suivi d'un verbe de déplacement (E. Egorova et al., 2016)
- Implémenter au sein de la plateforme PERDIDO les règles permettant de catégoriser les différentes formes de mouvements fictifs

Mouvement fictif

Descriptions de scènes statiques et dynamiques

Descriptions statiques

1. Description d'une scène d'un point de vue static

(10) Beyond, the desert hills rose to the Russian-China border.

2. Description d'une scène basée sur la connaissance

(11) The mountain range goes from Canada to Mexico

Descriptions dynamiques

3. Décrit le déplacement implicite d'un objet mobile (narrateur, . . .)

(12) The highway will enter California soon.

(13) The ridge went on forever, but after what seemed an age. . .

Mouvement fictif

Descriptions de scènes statiques et dynamiques

Descriptions statiques

1. Description d'une scène d'un point de vue static

(10) Beyond, the desert hills rose to the Russian-China border.

2. Description d'une scène basée sur la connaissance

(11) The mountain range goes from Canada to Mexico

Descriptions dynamiques

3. Décrit le déplacement implicite d'un objet mobile (narrateur, . . .)

(12) The highway will enter California soon.

(13) The ridge went on forever, but after what seemed an age. . .

SOMMAIRE

1 Introduction

2 Annotation de l'aspect statique

3 Annotation de l'aspect dynamique

4 Mouvement fictif

5 **Conclusion**

Conclusion

Extraction automatique du contexte géographique statique et dynamique

- Cas d'applications aux humanités numériques :
  - extraction des noms de lieux pour une cartographie romanesque
  - extraction des expressions de mouvements pour la reconstruction d'itinéraires
  - identification et catégorisation des expressions de mouvements fictifs

Travaux en cours et perspectives

- Mise à disposition d'outils pour l'extraction d'informations géographiques à partir de corpus textuels
  - Adaptation de la plateforme et des webservices existants pour les humanités numériques (http ://erig.univ-pau.fr/PERDIDO)
- Etendre les règles d'extraction de contextes dynamiques pour des corpus différents
- Projet ANR CHOUCAS (2017-2020) pour l'aide la localisation de victimes en montagne

Merci de votre attention

CONTACT

Ludovic Moncla (IRENav)
ludovic.moncla@ecole-navale.fr

Mauro Gaio (LIUPPA)
mauro.gaio@univ-pau.fr

Ekaterina Egorova (UZH)
ekaterina.egorova@geo.uzh.ch

Christophe Claramunt (IRENav)
christophe.claramunt@ecole-navale.fr

ECOLE NAVALE

UNIVERSITÉ DE PAU ET DES PAYS DE L'ADOUR

University of Zurich[UZH]
Department of Geography

Methodology

Extracting street names via CQL requests

TXM platform

- `http://sf.net/projects/txm`
- Implements lexicometric methods for content analyses of text corpora
- CQL request find occurrences of specific entities and TXM produces a concordancer

CQL requests used in TXM

```
[lemma="rue"%cd][word!="\.|\,|\;|\!|\?|\...|-|une|\-|où
\ainsi|et|aurait|-l"%c]? [word!="\.|\,|\;|\!|\?|\...|-
|une|\-|où\ainsi|et|aurait|-l"%c] ?  [word!="\p{Lu}.*"&
word!=\Ça|Ah|O|Venez|Et|M|L."]
```

```
[frlemma="rue"%cd] [word!="\p{P}+"] ? [word!="\p{P}+"]
? [word!="\p{P}+"] ? [word="\p{Lu}.*"]
```

Methodology

Named entity recognition and classification

PERDIDO NER processing chain

- `http://erig.univ-pau.fr/PERDIDO/`
- A geographically oriented NER system
- Retrieve, tag and extract extended named entities
- Produce annotated XML files and a concordancer

Cascaded finite-state transducers

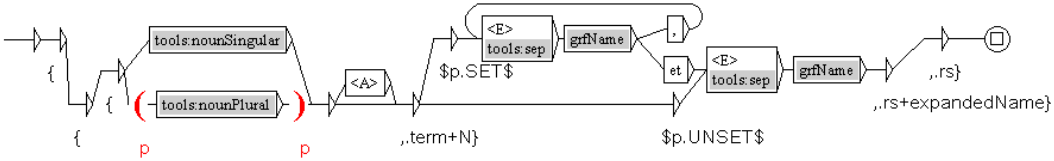

- Transducers are developed and processed with the Unitex platform

Results

Extraction of street names

Evaluation scores

	Precision	Recall	F_1-score
TXM	98.3	98.5	98.4
PERDIDO	99.7	99.0	99.3

Classified errors

	TXM	PERDIDO
# of results	2607	2583
false positive	44	7
false negative	39	26
malformed	127	4

Results
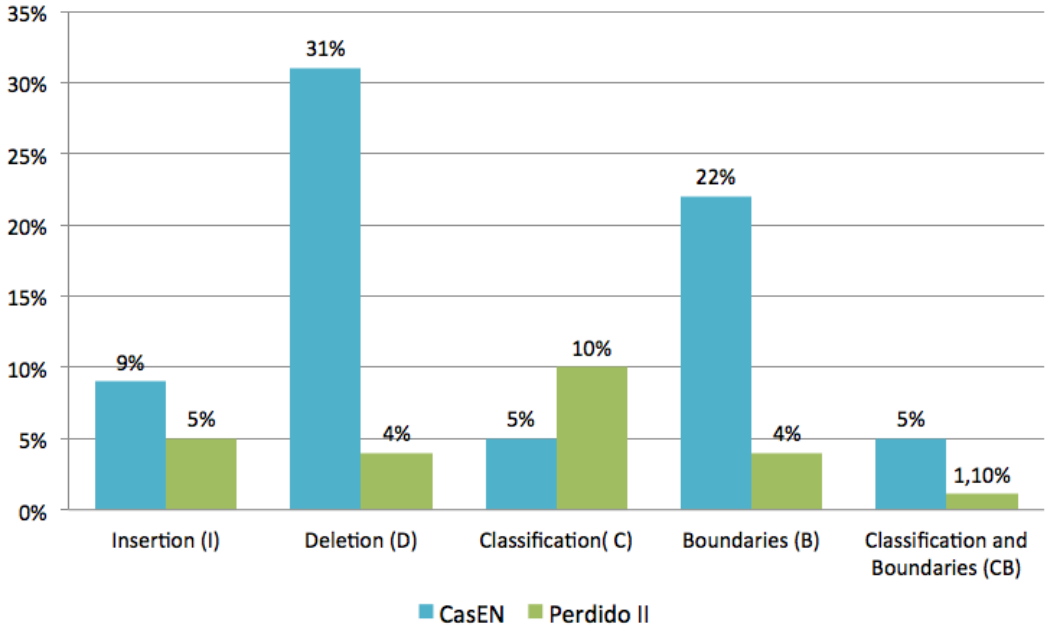
PERDIDO vs CasEN