Cartographier les odonymes de Paris cités dans les romans du XIXème siècle

L. Moncla, M. Gaio, et T. Joliveau

ludovic.moncla@liris.cnrs.fr

SOMMAIRE

1 Introduction

2 Méthodologie

3 Représentations cartographiques

4 Conclusion

Introduction

Relations entre littérature et géographie

- Vers une plateforme capable
  - d'extraire, de localiser, de cartographier et d'analyser les lieux de Paris mentionnés dans les romans
- destinée et conçu pour les
  - urbanistes, historiens, experts littéraires, touristes culturels, . . .

Objectifs

- simplifier l'extraction d'information spatiale des textes littéraires
- visualiser les lieux et l'espace dans les récits

Humanités numériques

Analyse spatiale d'oeuvre littéraires

- Méthodes d'extraction automatique d'informations à partir de textes
- Visualisation et interpretation automatique (ou semi-automatique) des textes
- Représentation de l'information et des relations spatiales et sociales

Corpus de romans du XIXème

- 31 romans dont l'action est principalement localisée à Paris
  Le père Goriot, Balzac 1835 ; Les misérables, Hugo 1862 ; L'Assommoir, Zola 1877 ; . . .
- Couvrant différentes période du XIXème
- Pré-traitement pour la correction des erreurs liés à l'OCR

SOMMAIRE

1 Introduction

2 Méthodologie

3 Représentations cartographiques

4 Conclusion

Méthodologie

Vers une méthode interactive pour l'exploration d'un corpus de romans

- Combinaison d'une méthode d'annotation automatique et d'une approche textométrique

Trois étapes principales :

- Repérer et annoter les odonymes (geoparsing)
- Localiser les odonymes grâce à des ressources historiques et géographiques (geocoding)
- Créer des représentations cartographiques adaptées aux spécificités de l'espace littéraire

Entités Spatiales Nommées Etendues

- Entités construites autour d'un nom propre et composées d'un ou plusieurs termes géographiques
- Plusieurs niveaux d'imbrication possibles

(1) a. *la rue* *La Fayette*

b. *le quartier de la* *Goutte-d'Or*

Annotation automatique des odonymes

Plateforme PERDIDO

- Traitement automatique pour l'annotation d'informations géographiques
- Recherche et annote les entités nommées étendues et les informations spatiales associées (relations spatiales, verbes de déplcement, etc.)
- Produit un résultat au format TEI et un concordancier

```
<placeName>
  <geogName type="R" subtype="ST">
    <geogFeat>
      <w lemma="rue" type="N">rue</w>
    </geogFeat>
    <w lemma="de" type="PREP">de</w>
    <name>
      <w lemma="Rivoli" type="NPr">Rivoli</w>
    </name>
  </geogName>
</placeName>
```

Analyse textométrique

Plateforme TXM

- Implémente des méthodes de textométrie pour l'analyse de grands corpus
- Utilise des requêtes CQL pour rechercher des occurrences d'entités et produit un concordancier

Requêtes CQL

```
[lemma="rue"%cd][word!="\.|\,|\;|\!|\?|\...|-|une|\-|où
\ainsi|et|aurait|-l"%c]? [word!="\.|\,|\;|\!|\?|\...|-
|une|\-|où\ainsi|et|aurait|-l"%c] ?  [word!="\p{Lu}.*"&
word!=\Ça|Ah|O|Venez|Et|M|L."]
```

```
[frlemma="rue"%cd] [word!="\p{P}+"] ? [word!="\p{P}+"]
? [word!="\p{P}+"] ? [word="\p{Lu}.*"]
```

Expérimentations

Evaluation de la reconnaissance automatique des odonymes

	CQL-TXM	Perdido
occurrences des odonymes trouvées à tort (faux positif)	286	88
occurrences des odonymes non trouvées (faux négatif)	11	117
occurrences des odonymes trouvées (vrai positif)	3573	3467
Total d'occurrences trouvées	3859	3555
Précision	0.926	0.975
Rappel	0.997	0.967
F-score	0.960	0.971

SOMMAIRE

1 Introduction

2 Méthodologie

3 Représentations cartographiques

4 Conclusion

Occurrences des noms de rues

Densité des citations de noms de rues

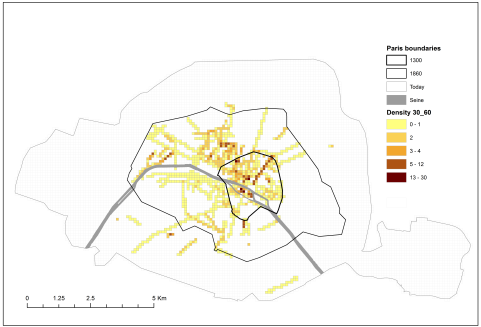

(a) dans les romans publiés entre 1830 et 1860

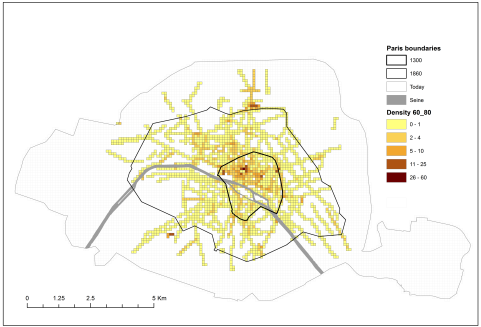

(b) dans les romans publiés entre 1860 et 1880

Densité des citations de noms de rues

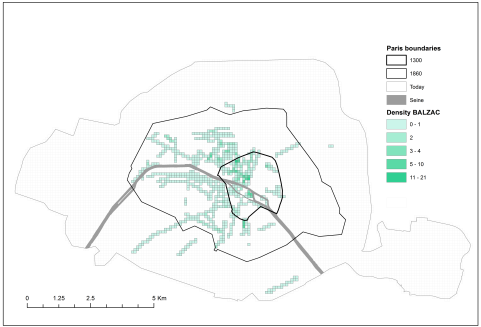

(a) dans les romans de Balzac

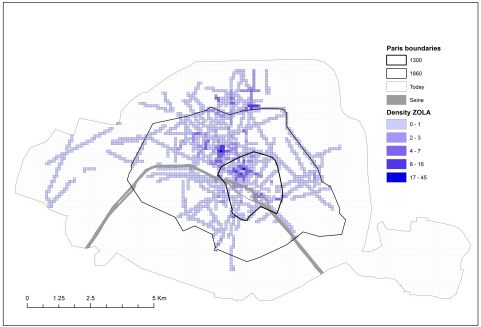

(b) dans les romans de Zola

Empreinte spatiale d'un roman (L'Assommoir, Zola)

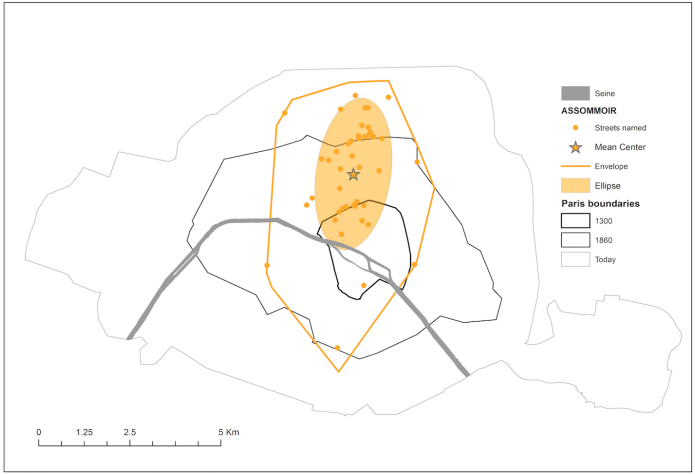

SOMMAIRE

1 Introduction

2 Méthodologie

3 Représentations cartographiques

4 Conclusion

Conclusion

Combinaison de méthodes TAL et textométriques pour l'extraction

- simplification et automatisation d'un partie du processus
- réduction importante du nombre de faux positifs
- génération d'un texte annoté au format TEI permettant l'interopérabilité entre les deux types d'approches

Plateforme d'extraction et de représentation d'informations spatiales

- exploration interactive de l'espace littéraire à travers l'espace urbain et fictionnel
- vers une meilleure intégration des informations géo-sémantique pour l'interprétation du contexte (relations spatio-temporelles, verbes, évènement, personnages, . . .)

Merci de votre attention

CONTACT

Ludovic Moncla (INSA-Lyon)
ludovic.moncla@liris.cnrs.fr

Mauro Gaio (LIUPPA)
mauro.gaio@univ-pau.fr

Thierry Joliveau (EVS)
thierry.joliveau@univ-st-etienne.fr